

M1SOL041 – Représentation et traitement des documents électroniques

La donnée dans tous ses états

Rimane Karam, Marine Tiger

15/09/26

Maison de la Recherche, Sorbonne Université

Introduction

Qu'est-ce qu'une donnée ?

- Dans notre contexte, une donnée = une information **encodée sous format numérique**. Par nature, tous les contenus numériques sont encodés.
- Ces contenus sont structurés selon des **standards**, afin d'être lus et partagés : les **formats**.
- Le format d'un fichier est indiqué dans son extension.
Ex : .pdf, .epub, .docx, .odt, .txt ...

Introduction

Quels formats pour quelles possibilités d'action sur le contenu ?

- Certains formats sont **éditables** (.doc/.docx, .odt, ...) = on peut les manipuler en écrivant ou réécrivant des éléments ;
- Certains garantissent un **aperçu fixe** du contenu (.pdf) ;
- Certains sont associés à des environnements techniques. Ex : un fichier .page ne peut être ouvert que sur un Mac

Introduction

On distingue :

- Les formats « propriétaires » : définis par une organisation ou un propriétaire **privé**, qui détient les droits de propriété intellectuelle.
Ex : .azw (Kindle), .docx (Word)...
- Les formats « libres » ou « ouverts » : rendus **public** par son créateur ; aucune restriction légale n'empêche leur libre utilisation = formats **libres de droits**.
Ex : .odt, .epub, .csv, .txt...

Introduction

Deux types de données :

- alphanumériques : textes et nombres (.txt, .odt, .docx...)
- audiovisuelles : images, sons et vidéos (.png, .wav, .mp3...)

Introduction

Comprendre à partir d'une étude de cas

Le projet :

→ Permettre une **fouille textuelle numérique** à partir de manuscrits

Le point de départ :

→ Les manuscrits sont disponibles et consultables dans une bibliothèque

La donnée dans tous ses états

1. Du support physique au fichier numérique

Fil rouge : comment passer d'un support physique à un document disponible sur son ordinateur ?

1. Du support physique au fichier numérique

Comment a-t-on obtenu nos données ?

- Photographies ?
- Transcriptions manuelles ?
- Numérisation ?
- Scraping ? (dans ce cas, il n'y a pas de support physique au départ)
- ...

جن السماوات فقال
له على الباشا ياحنوي
ورما الحاريد و طالع
عن نوس على المينة
ولما صعد بالبر اشتغل
ضرب المذق فقع على المركب
فقلع على
بوجي
في البحر وتمر عن نوس في البر
فاحتلم عن نوس بات ذلك
ملعوب و ما بقا يخلصه الا
ضرب السيف فركب
ذات النور وحمل على


وحمل على الاعداء
وضرب الاول و ماه
والثاني ما ابقاه
و شق عمره
بين الصفوف و نفذ
قوة و اقتدارا طالع
البر و الدم شخب
منه لانه اخرج نفوس
لديروا الباب فتح له
البراهب و صرخ اهلا
وسهلا بفلين و
قال له يا ابونا انا اليك
ظيقت قال له مرحبا

1. Du support physique au fichier numérique


ATR = Automatic Text Recognition (reconnaissance automatique de texte)

- **OCR** (reconnaissance optique de caractères)
- **HTR** (reconnaissance de caractères manuscrits)


1. Du support physique au fichier numérique



1. Du support physique au fichier numérique



1. Du support physique au fichier numérique



```
<Heading type="sub">
<Line>Airs sur la même coupe.</Line>
</Heading>
<Paragraph>
  <Line>Pour obtenir celle qu'il aime,</Line>
  <Line>ou Mes chers amis, dans cette vie (<Emphasis
type="italic">Calife de</Emphasis></Line>
  <Line><Emphasis type="italic">Bagdad</Emphasis>),</Line>
  <Line>ou Comment ici ne pas se plaire (<Emphasis
type="italic">Préven-</Emphasis></Line>
  <Line><Emphasis type="italic">tions</Emphasis>).
1025.</Line>
  <Line>Pour le bonheur de vos familles. 1028.</Line>
  <Line>D'un jeune plumet vif et tendre. 1114.</Line>
  <Line>En proie au chaprin qui me tue (<Emphasis
type="italic">Gardes-</Emphasis></Line>
  <Line><Emphasis type="italic">marine</Emphasis>),</Line>
  <Line>ou Je m'appel Boniface, Blaise (de M.</Line>
  <Line><Emphasis type="italic">Blaise</Emphasis>).
1525.</Line>
  <Line>En France même, je l'espère. 1973.</Line>
  <Line>Dans la solitaire bourgade (<Emphasis
type="italic">romance</Emphasis>), 2025.</Line>
  <Line>Vous partez brillante et parée (<Emphasis
type="italic">le Bouquet de</Emphasis></Line>
  <Line><Emphasis type="italic">Bal, romance</Emphasis>).
2306.</Line>
</Paragraph>
```

1. Du support physique au fichier numérique

A retenir :

- **vérité terrain (VT)** constituée par l'humain : compétences linguistiques / paléographiques
- cette VT = base de donnée grâce à laquelle on **entraîne le modèle** à reconnaître les caractères du texte original
- des **données de test** non fournies au modèle en amont permettent d'évaluer sa performance

1. Du support physique au fichier numérique

Reconnaissance automatique de caractères

- = accessible à toutes les langues ?
- = performante sur toutes les langues ?

=> Que faire quand ces technologies ne sont pas assez performantes sur nos données ?



الجزء الأول - كتيب رقم ١ [منام السلطان، تفسيره وعواقبه]

قال الراوى يا ساده يا كرام، صلوا على خير الأنام ! اما بعد، فانه كان بقديم الزمان وسالف العصر والأوان، ملك من ملوك الاسلام يقال له الصالح ايوب¹ - رحمة الله عليه، وعلى من سبقنا الى رحمة الله - وكان ذلك الملك من اهل الله ظاهراً وباطناً، وكان كرسى ملكه في مصر العديه²، وله زوجة مثله على بركات الله. فاتفق لذلك الملك ليله من احدى الليالى، كانت ليلة الجمعة، فنظر منام هائل الأحلام. فلما انتبه من منامه ولذيق احلامه، نسي ما رآه، ففز وصار يدور حواله الفرشه ويتفحص الشرشف³، وهو يقول : لا حول ولا قوة الا بالله العلي العظيم ! وبين راح المنام ؟ فانتبهت زوجته شجرة الدر⁴، لفته عمال يلوب⁵ ويتحول⁶ فظنت انه فاقد له شيء. ففرت واثبه على الأقدام وقالت له : ما لك يا ملك الزمان؟ فقال لها : نظرت منام وشدد منى، فمل، نظرتلى، اباه ؟ قالت له : نعم ! نظرت هارسلته الى هاراك الآغا

La donnée dans tous ses états

1. Du support physique au fichier numérique

Notions clés : reconnaissance automatique de caractères (ATR = OCR/HTR) ; vérité terrain ; transcription manuelle VS automatique

2. Du fichier disponible numériquement au fichier exploitable

Fil rouge : comment rendre un fichier exploitable numériquement ?



L



2. Du fichier disponible numériquement au fichier exploitable

Le format .doc / .docx / .odt...

- ... est un format adapté à l'édition d'un texte
- ... mais généralement inexploitable sur des logiciels de textométrie et dans une perspective de programmation (Python)

= 20 ans d'édition de texte... pour rien ?

الجزء الأول - كتيب رقم ١

[منام السلطان، تفسيره وعواقبه]

قال الراوى يا ساده يا كرام، صلوا على خير الأنام ! اما بعد، فانه كان بقديم الزمان وسالف العصر والأوان، ملك من ملوك الاسلام يقال له الصالح ايوب - رحمة الله عليه، وعلى من سبقنا الى رحمة الله - وكان ذلك الملك من اهل الله ظاهراً وباطناً، وكان كرسى ملكه في مصر العديه، وله زوجة مثله على بركات الله. فاتفق لذلك الملك ليله من احدى الليالى، كانت ليلة الجمعة، فنظر منام هائل الأحلام. فلما انتبه من منامه ولذيد احلامه، نسي ما رآه، ففز وصار يدور حواله الفرشه ويتنفض الشريشف، وهو يقول : لا حول ولا قوة الا بالله العلي العظيم ! وين راح المنام ؟ فانتبهت زوجته شجرة الدر، لفته عمال يلوب ويتحول فظننت انه فاقد له شيء. ففرت واثبه على الأقدام وقالت له : ما لك يا ملك الزمان؟ فقال لها : نظرت منام وشترد مني فهل نظرتلى اياه ؟ قالت له : نعم ! نظرت وارسلته الى وزيرك الآغا شاهين.

قال... فلما سمع الملك ذلك الكلام، طاب خاطره وانيسط، وقام طلع على قاعة عرب، سار حتى يصلى الصبح ويقرأ اوراده. اما الملكة، حالاً ارسلت خبر الى الوزير شاهين، بانه الملك نظر منام وراح من باله، فستلنى عنه، قلت له : ارسلت لك اياه للوزير فانا حدفته عليك، فاعرف كيف يكون جوابك له. واما الملك، فانه بعد ما صلى وقراء اوراده، بعث طلب الآغا شاهين فحضر الى بين يديه، فدخل اخذ انكه وصبح عليه، فامر له الملك بالجلوس فجلس، فقال له : هل جبت لى تفسير المنام الذى ارسلته لك شجرة الدر؟ قال له : افندم، وصلنى المنام ولكن ارسلته الى شيخ الأزهر، الشيخ محمد دقيق العيد حتى يجيب لك شرحه. قال له الملك : عفرم ! وبعث طلب الشيخ محمد. فقام الشيخ حضر الى بين يديه وسلم عليه فامر له الملك بالجلوس فجلس، فقال له الملك : جبت لنا شرح المنام ؟ قال له : نعم افندم ! وكان، يا ساده، الوزير شاهين ارسل للشيخ محمد خبر بصورة الدعوى قبل حضوره لعند الملك. فمد يده الشيخ لتحت باطه، وطالع كتاب التفسير، وقال للملك : افندم، سعادتك نظرت بنومك نار حواله مصر، فصار لك منها رجّه عظيمه. وبعد ذلك اقبل من جهة بحر النيل طيور صاروا يغثوا من البحر ويرشوا على النار، وبينهم غراب اسود وهو ساطى على جميع الطيور. فانه لازال يطفئ بالنار حتى احمد لهيها. فقال الملك : اينعم، وعزة الله! هذا هو المنام بعينه، ولكن ما يكون تفسيره ؟ قال له الشيخ : افندم سوف ينتشئ بدولتك وجاقات ويظهر بينهم شراق يكون نجمه عالى، ويخذه السعد وهو جبار وقته. فيصير ضد الى اعداء الدين، ويفتح فتوحات عظيمه، ويكتب بديوان المغازيين فى سبيل الله، ويصير له يذكار وتاريخ، وتترحم عليه العباد الى ابد الأبد، ما قام قائم وقعد. وهذا، افندم، تفسير المنام.

قال صاحب التاريخ ان الوزير شاهين، لما ارسل خبر للشيخ محمد بصورة الدعوى كما قدمنا، فتح الشيخ الكتاب وجد المنام على حاشية الكتاب، وتفسيره تحته، وهو لم يراه سابق.

قال... واما الملك، فانه كان رجل مُتَصَوِّفٌ، ما هو دنيوي وليس له رغبه بمتاع الدنيا، ولا يقارش بيت المال ابداً، بل يأكل من كد يمينه. وكان يشغل طواقي ويهاديها الى الملوك والأعيان، وهم يهادوه بلقائنها دراهم يعناش فيهم. وقيل انه من لبس طاقيه من شغله، يكشف الله على بصيرته ويتصل ويصير من عباد الله الصالحين. فلما سمع من الشيخ محمد تفسير المنام ذلك النهار، التفت للوزير شاهين وقال له : يا وزير ! وعزة الله، اصبحت بهذا النهار لا امتلك شيئاً من المعامله، فمن اين لنا ان ننشئ وجاقات، ونملك ذلك الأرب الذى تكلم به جناب الشيخ ؟ قال له : افندم، ان الله تعالى كل يوم هو فى شان ! ويخلق ما لا تعلمون، لأنه الذى يعلم الله ما هو يعلم احد. قال الملك : توكلنا على الله ! واكرم الشيخ بطاقيه واصرفه.

2. Du fichier disponible numériquement au fichier exploitable

Au sujet du format .txt :

- Il est plus simple à ouvrir, consulter, stocker, envoyer ;
- Il est plus simple à convertir vers d'autres formats le cas échéant ;
- Il est directement exploitable par des logiciels de textométrie ou en programmation

2. Du fichier disponible numériquement au fichier exploitable

Le fichier .txt = texte brut, ou « plain text » : pas de mise en forme.

=> Mais dans ce cas, comment **récupérer une structure de document** ? (Titre, chapitre, autre division pertinente...)

= où et comment ajouter ces informations face à un fichier .txt ?

2. Du fichier disponible numériquement au fichier exploitable

Remarques préliminaires :

- se demander ce que l'on souhaite faire de ses données : le format de conversion choisi doit être **utile à l'objet de recherche fixé**
- se demander quelles informations on souhaite ajouter à ses données, une étape toujours **liée à l'objet de recherche fixé**

2. Du fichier disponible numériquement au fichier exploitable

Dans mon cas, je veux un fichier :

- exploitable sur un logiciel de textométrie

ET

- contenant des informations sur la langue (catégories grammaticales/morpho-syntaxiques)

2. Du fichier disponible numériquement au fichier exploitable

Quel est l'intérêt d'ajouter des **métadonnées** ?

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <root>
3 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="الْجُزء" atbseg="الْجُزء" lex="الجزء < جُزء </w>
4 <w asp="na" cas="g" gen="m" mod="na" num="s" per="na" pos="adj" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="الأَوَّل" atbseg="الأَوَّل" lex="الأول < أَوَّل </w>
5 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="-" atbseg="-" lex="-" > - </w>
6 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="i" vox="na" atbtok="كُتِبَ" atbseg="كُتِبَ" lex="كتيب < كُتِبَ </w>
7 <w asp="na" cas="g" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="c" vox="na" atbtok="رَقْم" atbseg="رَقْم" lex="رقم < رَقْم </w>
8 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="digit" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na"
  prc2="na" prc3="na" stt="na" vox="na" atbtok="١" atbseg="١" lex="١ < ١ </w>
9 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="[" atbseg="[" lex="[" > [ </w>
10 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="i" vox="na" atbtok="مَنَام" atbseg="مَنَام" lex="منام < مَنَام </w>
11 <w asp="na" cas="g" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="السُّلْطَان" atbseg="السُّلْطَان" lex="سلطان < السُّلْطَان </w>
12 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="," atbseg="," lex="," > , </w>
13 <w asp="na" cas="n" gen="m" mod="na" num="s" per="na" pos="noun" enc0="3ms_poss" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="c" vox="na" atbtok="تَفْصِيْرٌ+ْ" atbseg="تَفْصِيْرٌ+ْ" lex="تفسيره < تَفْصِيْرٌ+ْ </w>
14 <w asp="na" cas="u" gen="f" mod="na" num="p" per="na" pos="noun" enc0="3ms_poss" enc1="None" enc2="None" prc0="0" prc1="0"
  prc2="wa_sub" prc3="0" stt="c" vox="na" atbtok="وَعَوَاقِبُ+ْ" atbseg="وَعَوَاقِبُ+ْ" lex="عاقبة < وعواقبه </w>
15 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="]" atbseg="]" lex="]" > ] </w>
16 <w asp="p" cas="na" gen="m" mod="i" num="s" per="3" pos="verb" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="na" vox="a" atbtok="قَالَ" atbseg="قَالَ" lex="قال < قَالَ </w>
17 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="الرَّاوِي" atbseg="الرَّاوِي" lex="راوي < الراوي </w>
18 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="part_voc" enc0="0" enc1="None" enc2="None" prc0="na" prc1="0"
  prc2="0" prc3="0" stt="na" vox="na" atbtok="يَا" atbseg="يَا" lex="يا < يَا </w>
```



الجزء الأول - كتيب رقم ١ [منام السلطان، تفسيره وعواقبه]

قال الراوى يا ساده يا كرام، صلوا على خير الأنام ! اما بعد، فانه كان بتقديم الزمان وسالف العصر والأوان، ملك من ملوك الاسلام يقال له الصالح ايوب¹ - رحمة الله عليه، وعلى من سبقنا الى رحمة الله - وكان ذلك الملك من اهل الله ظاهراً وباطناً، وكان كرسى ملكه في مصر العديه²، وله زوجة مثله على بركات الله. فاتفق لذلك الملك ليله من احدى الليالى، كانت ليلة الجمعة، فنظر منام هائل الأحلام. فلما انتبه من منامه ولذيق احلامه، نسي ما رآه، ففز وصار يدور حواله الفرشه ويتفُض الشرشف³، وهو يقول : لا حول ولا قوة الا بالله العلي العظيم ! وبين راح المنام ؟ فانتبهت زوجته شجرة الدر⁴، لفته عمال يلوب⁵ ويتحول⁶ فظنت انه فاقد له شيء. ففزت واثبه على الأقدام وقالت له : ما لك يا ملك الزمان؟ فقال لها : نظرت منام وشَد منى، فمل، نظرتلى، اباه ؟ قالت له : نعم ! نظرت هارسلته الى هارسك الآغا

الجزء الأول - كتيب رقم ١

[منام السلطان، تفسيره وعواقبه]

قال الراوى يا ساده يا كرام، صلوا على خير الأنام ! اما بعد، فانه كان بقديم الزمان وسالف العصر والأوان، ملك من ملوك الاسلام يقال له الصالح ايوب - رحمة الله عليه، وعلى من سبقنا الى رحمة الله - وكان ذلك الملك من اهل الله ظاهراً وباطناً، وكان كرسى ملكه في مصر العديه، وله زوجة مثله على بركات الله. فاتفق لذلك الملك ليله من احدى الليالى، كانت ليلة الجمعة، فنظر منام هائل الأحلام. فلما انتبه من منامه ولذيد احلامه، نسي ما رآه، ففز وصار يدور حواله الفرشه ويتنفض الشريشف، وهو يقول : لا حول ولا قوة الا بالله العلي العظيم ! وين راح المنام ؟ فانتبهت زوجته شجرة الدر، لفته عمال يلوب ويتحول فظننت انه فاقد له شيء. ففرت واثبه على الأقدام وقالت له : ما لك يا ملك الزمان؟ فقال لها : نظرت منام وشترد مني فهل نظرتلى اياه ؟ قالت له : نعم ! نظرت وارسلته الى وزيرك الآغا شاهين.

قال... فلما سمع الملك ذلك الكلام، طاب خاطره وانيسط، وقام طلع على قاعة عرب، سار حتى يصلى الصبح ويقرأ اوراده. اما الملكة، حالاً ارسلت خبر الى الوزير شاهين، بانه الملك نظر منام وراح من باله، فستلنى عنه، قلت له : ارسلت لك اياه للوزير فانا حدفته عليك، فاعرف كيف يكون جوابك له. واما الملك، فانه بعد ما صلى وقراء اوراده، بعث طلب الآغا شاهين فحضر الى بين يديه، فدخل اخذ انكه وصبح عليه، فامر له الملك بالجلوس فجلس، فقال له : هل جبت لى تفسير المنام الذى ارسلته لك شجرة الدر؟ قال له : افندم، وصلنى المنام ولكن ارسلته الى شيخ الأزهر، الشيخ محمد دقيق العيد حتى يجيب لك شرحه. قال له الملك : عفرم ! وبعث طلب الشيخ محمد. فقام الشيخ حضر الى بين يديه وسلم عليه فامر له الملك بالجلوس فجلس، فقال له الملك : جبت لنا شرح المنام ؟ قال له : نعم افندم ! وكان، يا ساده، الوزير شاهين ارسل للشيخ محمد خبر بصورة الدعوى قبل حضوره لعند الملك. فمد يده الشيخ لتحت باطه، وطالع كتاب التفسير، وقال للملك : افندم، سعادتك نظرت بنومك نار حواله مصر، فصار لك منها رجّه عظيمه. وبعد ذلك اقبل من جهة بحر النيل طيور صاروا يغثوا من البحر ويرشوا على النار، وبينهم غراب اسود وهو ساطى على جميع الطيور. فانه لازال يطفئ بالنار حتى احمد لهيها. فقال الملك : اينعم، وعزة الله! هذا هو المنام بعينه، ولكن ما يكون تفسيره ؟ قال له الشيخ : افندم سوف ينتشئ بدولتك وجاقات ويطهر بينهم شراق يكون نجمه عالى، ويخدّمه السعد وهو جبار وقته. فيصير ضد الى اعداء الدين، ويفتح فتوحات عظيمه، ويكتب بديوان المغازيين فى سبيل الله، ويصير له يذكّار وتاريخ، وتترحم عليه العباد الى ابد الأبد، ما قام قائم وقعد. وهذا، افندم، تفسير المنام.

قال صاحب التاريخ ان الوزير شاهين، لما ارسل خبر للشيخ محمد بصورة الدعوى كما قدمنا، فتح الشيخ الكتاب وجد المنام على حاشية الكتاب، وتفسيره تحته، وهو لم يراه سابق.

قال... واما الملك، فانه كان رجل مُتَصَوِّفٌ، ما هو دنيوي وليس له رغبه بمتاع الدنيا، ولا يقارش بيت المال ابداً، بل يأكل من كد يمينه. وكان يشغل طواقي ويهاديها الى الملوك والأعيان، وهم يهادوه بلقائنها دراهم يعناش فيهم. وقيل انه من لبس طاقيه من شغله، يكشف الله على بصيرته ويتصل ويصير من عباد الله الصالحين. فلما سمع من الشيخ محمد تفسير المنام ذلك النهار، التفت للوزير شاهين وقال له : يا وزير ! وعزة الله، اصبحت بهذا النهار لا امتلك شيئاً من المعامله، فمن اين لنا ان ننشئ وجاقات، ونملك ذلك الأرب الذى تكلم به جناب الشيخ ؟ قال له : افندم، ان الله تعالى كل يوم هو فى شان ! ويخلق ما لا تعلمون، لأنه الذى يعلم الله ما هو يعلم احد. قال الملك : توكلنا على الله ! واكرم الشيخ بطاقيه واصرفه.

```
1 <?xml version="1.0" encoding="utf-8"?>
2 <root>
3 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="الْجُزء" atbseg="الْجُزء" lex="الجزء < جُزء </w>
4 <w asp="na" cas="g" gen="m" mod="na" num="s" per="na" pos="adj" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="الأَوَّل" atbseg="الأَوَّل" lex="الأول < أَوَّل </w>
5 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="-" atbseg="-" lex="-" > - </w>
6 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="i" vox="na" atbtok="كُتِبَ" atbseg="كُتِبَ" lex="كتب < كُتِبَ </w>
7 <w asp="na" cas="g" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="c" vox="na" atbtok="رَقْم" atbseg="رَقْم" lex="رقم < رَقْم </w>
8 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="digit" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na"
  prc2="na" prc3="na" stt="na" vox="na" atbtok="١" atbseg="١" lex="١ < ١ </w>
9 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="[" atbseg="[" lex="[" > [ </w>
10 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="i" vox="na" atbtok="مَنَام" atbseg="مَنَام" lex="نام < مَنَام </w>
11 <w asp="na" cas="g" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="السُّلْطَان" atbseg="السُّلْطَان" lex="سلطان < السُّلْطَان </w>
12 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="," atbseg="," lex="," > , </w>
13 <w asp="na" cas="n" gen="m" mod="na" num="s" per="na" pos="noun" enc0="3ms_poss" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="c" vox="na" atbtok="تَفْصِيْرٌ+ْ" atbseg="تَفْصِيْرٌ+ْ" lex="تفسيره < تَفْصِيْرٌ+ْ </w>
14 <w asp="na" cas="u" gen="f" mod="na" num="p" per="na" pos="noun" enc0="3ms_poss" enc1="None" enc2="None" prc0="0" prc1="0"
  prc2="wa_sub" prc3="0" stt="c" vox="na" atbtok="وَعَوَاقِبُ+ْ" atbseg="وَعَوَاقِبُ+ْ" lex="عاقبة < وعواقبه </w>
15 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="punc" enc0="na" enc1="None" enc2="None" prc0="na" prc1="na" prc2="na"
  prc3="na" stt="na" vox="na" atbtok="]" atbseg="]" lex="]" > ] </w>
16 <w asp="p" cas="na" gen="m" mod="i" num="s" per="3" pos="verb" enc0="0" enc1="None" enc2="None" prc0="0" prc1="0" prc2="0"
  prc3="0" stt="na" vox="a" atbtok="قَالَ" atbseg="قَالَ" lex="قال < قَالَ </w>
17 <w asp="na" cas="u" gen="m" mod="na" num="s" per="na" pos="noun" enc0="0" enc1="None" enc2="None" prc0="Al_det" prc1="0" prc2="0"
  prc3="0" stt="d" vox="na" atbtok="الرَّاوِي" atbseg="الرَّاوِي" lex="راوي < الراوي </w>
18 <w asp="na" cas="na" gen="na" mod="na" num="na" per="na" pos="part_voc" enc0="0" enc1="None" enc2="None" prc0="na" prc1="0"
  prc2="0" prc3="0" stt="na" vox="na" atbtok="يَا" atbseg="يَا" lex="يا < يَا </w>
```

La donnée dans tous ses états

1. Du support physique au fichier numérique

Notions clés : reconnaissance automatique de caractères (ATR = OCR/HTR) ; vérité terrain ; transcription manuelle VS automatique

2. Du fichier disponible numériquement au fichier exploitable

Notions clés : conversion et différence entre les formats (.doc, .txt, .xml), métadonnées, objet de recherche

Ouvrir



data.csv

~/Python/la-formation-complete-python/chp-014_bases-de-la-data-science

Enregistrer



```
1 id,date,first_name,last_name,email,gender,ip_address,country,price_paid,tax
2 1,03/28/2021,Marylin,Alders,malders0@shop-pro.jp,Male,160.119.8.119,Canada,$5.36,
3 2,03/19/2021,Hinda,Harridge,hharridge1@gnu.org,Female,210.51.172.132,Canada,$8.32,
4 3,03/17/2021,Erl,Kilminster,ekilminster2@etsy.com,Male,213.8.101.145,United States,$3.73,20
5 4,03/19/2021,Grata,Brantl,gbrantl3@umn.edu,Female,5.140.237.101,United States,$3.70,20
6 5,03/24/2021,Kanya,Beasant,kbeasant4@jigsy.com,Male,106.252.162.233,Morocco,$9.24,20
7 6,03/25/2021,Titos,Braybrooke,tbraybrooke5@umn.edu,Female,173.100.21.179,United States,$5.82,
8 7,03/14/2021,Ava,Kencott,akencott6@phoca.cz,Female,118.251.45.43,Canada,$6.29,
9 8,03/08/2021,Codi,Feasley,cfeasley7@ed.gov,Male,26.190.191.249,France,$3.01,20
10 9,03/09/2021,Waylon,Heersema,wheersema8@tumblr.com,Male,63.242.174.112,Canada,$3.70,20
11 10,03/23/2021,Guglielma,Gookes,ggookes9@amazon.co.uk,Male,169.100.6.0,France,$9.05,
12 11,03/11/2021,Lief,Woodcraft,lwoodcrafta@sitemeter.com,Male,201.76.240.51,Canada,$5.71,
13 12,03/16/2021,Bailie,Wyman,bwymanb@lulu.com,Male,222.60.138.222,United States,$3.15,20
14 13,03/05/2021,Janice,Morillas,jmorillasc@miibeian.gov.cn,Female,24.25.198.252,Canada,$5.30,20
15 14,03/24/2021,Cull,Vassie,cvassied@unblog.fr,,18.203.61.94,France,$5.97,20
16 15,03/21/2021,Oralie,Maryon,omaryone@va.gov,Female,215.248.16.198,United States,$4.53,20
17 16,03/24/2021,Julina,Faint,jfaintf@amazon.co.jp,Female,96.193.4.151,United States,$4.10,20
18 17,03/27/2021,Eve,Allaway,eallawayg@ebay.co.uk,Female,184.107.59.156,United States,$6.44,20
19 18,03/20/2021,Esta,Boulden,ebouldenh@posterous.com,,220.109.140.190,United States,$3.16,20
20 19,03/16/2021,Judye,Behan,jbehani@google.es,Female,27.196.2.18,France,$4.90,20
21 20,03/01/2021,Sibeal,Mounch,smounchj@rakuten.co.jp,Male,218.17.7.177,Canada,$5.82,20
22 21,03/12/2021,Jeffrey,Stanman,jstanmank@latimes.com,Female,3.110.64.192,France,$5.55,20
23 22,03/05/2021,Mendie,Ayer,mayerl@squarespace.com,Male,166.97.124.52,Canada,$4.86,20
24 23,03/03/2021,Muriel,Pexton,mpextonm@bing.com,Male,113.10.187.192,Canada,$6.72,20
25 24,03/09/2021,Ermanno,Ghost,eghostn@webnode.com,Male,144.170.210.226,Canada,$9.79,
26 25,03/02/2021,Tod,Willetts,twilletso@artisteer.com,Male,101.42.146.88,Canada,$8.23,
27 26,03/14/2021,Nobe,Stobbart,nstobbartp@php.net,Female,126.155.177.249,United States,$9.90,
28 27,03/27/2021,Elyse,Glaysheer,eglaysheerq@mayoclinic.com,,165.91.52.42,United States,$5.88,
29 28,03/25/2021,Staford,London,slondonr@sphinn.com,Male,247.235.26.222,United States,$3.06,20
30 29,03/03/2021,Willabella,Robbins,wrobbinss@tinyurl.com,Female,129.71.210.8,,,$9.52,20
31 30,03/02/2021,Edi,Petru,epetrut@census.gov,Male,117.48.20.14,United States,$6.76,20
32 31,03/28/2021,Tommi,Ditchburn,tditchburnu@bbc.co.uk,Female,8.92.173.38,Morocco,$7.81,20
33 32,03/10/2021,Jillene,Baudi,jbaudiv@gizmodo.com,Female,184.161.57.67,France,$6.02,20
34 33,03/29/2021,Eadmund,Laurent,elaurentw@economist.com,Male,121.149.77.253,United States,$5.00,20
35 34,03/20/2021,Cam,Francescoccio,cfrancescocciox@si.edu,Female,177.11.5.62,United States,$5.34,20
36 35,03/02/2021,Trescha,McCudden,tmccuddeny@nbcnews.com,Female,195.84.81.131,France,$4.67,20
37 36,03/11/2021,Charmian,Greenleaf,cgreenleafz@tinypic.com,Male,46.184.249.156,France,$6.22,20
```




































	A	B	C	D	E	F	G	H	I	J	K	L	M
1	id	date	first_name	last_name	email	gender	ip_address	country	price_paid	tax			
2	1	03/28/2021	Marylin	Alders	malders0@shop-pro.jp	Male	160.119.8.119	Canada	\$5.36				
3	2	03/19/2021	Hinda	Harridge	hharridge1@gnu.org	Female	210.51.172.132	Canada	\$8.32				
4	3	03/17/2021	Erl	Kilminster	ekilminster2@etsy.com	Male	213.8.101.145	United States	\$3.73	20			
5	4	03/19/2021	Grata	Brantl	gbrantl3@umn.edu	Female	5.140.237.101	United States	\$3.70	20			
6	5	03/24/2021	Kanya	Beasant	kbeasant4@jigsy.com	Male	106.252.162.233	Morocco	\$9.24	20			
7	6	03/25/2021	Titos	Braybrooke	tbraybrooke5@umn.edu	Female	173.100.21.179	United States	\$5.82				
8	7	03/14/2021	Ava	Kencott	akencott6@phoca.cz	Female	118.251.45.43	Canada	\$6.29				
9	8	03/08/2021	Codi	Feasley	cfeasley7@ed.gov	Male	26.190.191.249	France	\$3.01	20			
10	9	03/09/2021	Waylon	Heersema	wheersema8@tumblr.com	Male	63.242.174.112	Canada	\$3.70	20			
11	10	03/23/2021	Guglielma	Gookes	ggookes9@amazon.co.uk	Male	169.100.6.0	France	\$9.05				
12	11	03/11/2021	Lief	Woodcraft	lwoodcrafta@sitemeter.com	Male	201.76.240.51	Canada	\$5.71				
13	12	03/16/2021	Bailie	Wyman	bwymانب@lulu.com	Male	222.60.138.222	United States	\$3.15	20			
14	13	03/05/2021	Janice	Morillas	jmorillasc@miibeian.gov.cn	Female	24.25.198.252	Canada	\$5.30	20			
15	14	03/24/2021	Cull	Vassie	cvassied@unblog.fr		18.203.61.94	France	\$5.97	20			
16	15	03/21/2021	Oralie	Maryon	omaryone@va.gov	Female	215.248.16.198	United States	\$4.53	20			
17	16	03/24/2021	Julina	Faint	jfaintf@amazon.co.jp	Female	96.193.4.151	United States	\$4.10	20			
18	17	03/27/2021	Eve	Allaway	eallawayg@ebay.co.uk	Female	184.107.59.156	United States	\$6.44	20			
19	18	03/20/2021	Esta	Boulden	ebouldenh@posterous.com		220.109.140.190	United States	\$3.16	20			
20	19	03/16/2021	Judy	Behan	jbehani@google.es	Female	27.196.2.18	France	\$4.90	20			
21	20	03/01/2021	Sibeal	Mounch	smounchj@rakuten.co.jp	Male	218.17.7.177	Canada	\$5.82	20			
22	21	03/12/2021	Jeffrey	Stanman	jstanmank@latimes.com	Female	3.110.64.192	France	\$5.55	20			
23	22	03/05/2021	Mendie	Ayer	mayerl@squarespace.com	Male	166.97.124.52	Canada	\$4.86	20			
24	23	03/03/2021	Muriel	Pexton	mpextonm@bing.com	Male	113.10.187.192	Canada	\$6.72	20			
25	24	03/09/2021	Frmanno	Ghost	ehostn@webnode.com	Male	144.170.210.226	Canada	\$9.79				

Rechercher Tout rechercher ☐ Affichage mis en forme ☐ Respecter la casse