

M1SOL041 : Représentation et traitement des documents électroniques

Cours 2 : Introduction au XML et au XML-TEI

Marine Tiger
marine.tiger@sorbonne-universite.fr

Littératures françaises et comparée ED19, CELLF, Sorbonne Université

22 septembre	Introduction en XML et XML-TEI
29 septembre	Structurer un document en TEI
06 octobre	XPath
13 octobre	XLST
20 octobre	DST + Initiation JSON
03 novembre	Exercices : XML et JSON avec Python

Introduction

Quiz sur Wooclap

Qu'est-ce que le XML ?

D'abord fut le GML...

Generalized Markup Language : développé par Charles Goldfarb, Edward Mosher et Raymond Lorie dans les années 1970.

→ Devient ensuite le Standard Generalized Markup Language (SGML) publié en 1986 et sert de base pour le HTML.

→ Problème : pas de normes pour utiliser le HTML.

... Puis apparut le XML

Extensible Markup Language : publié en 1998 par le W3C (*World Wide Web Consortium*)

→ Standard international.

→ Sert de base à d'autres langages : XHTML, XSLT etc...

Pourquoi utiliser le XML ?

- Indiquer la fonction structurelle ou des éléments sémantiques = expliciter certains aspects du texte
- Format facile à lire par les machines et l'humain
- Interopérable

Pourquoi utiliser le XML ?

Qu'est-ce qui peut être relevé dans un texte ?

Pourquoi utiliser le XML ?

Qu'est-ce qui peut être relevé dans un texte ?

- Type de document : poèmes, essais, pièces de théâtre...
- Forme du document : paragraphes, vers, etc...

Exemples :

- *Queen's Men Editions*
- *The Shelley-Godwin Archive*

Structure d'un document XML

Encodage basique

Le XML repose sur trois principes :

- Les balises sont appelées **éléments** ;
- Les éléments sont imbriqués ;
- L'imbrication est sous forme d'arborescence

```
<elementParent>  
  <elementEnfant> Texte </elementEnfant>  
</elementParent>
```

```
<Paragraphe>  
  <Phrase>  
    <mot> Toto </mot>  
  </Phrase>  
</Paragraphe>
```

Éléments et attributs

Élément = Le contenu. Doit toujours être entouré de deux balises du même nom.

Ex : `<paragraphe></paragraphe>` → l'élément est le paragraphe.

Les éléments ne doivent pas se chevaucher.

Ex : `<paragraphe><mot></paragraphe></mot>`

Attribut = Caractéristique du contenu. Ne peut pas réutilisé deux fois le même attribut.

Ex : `<paragraphe numero="1"></paragraphe>` → c'est le premier paragraphe.

Une structure bien formée

Un encodage XML est dit **bien formé** s'il respecte les règles de balisage ci-dessous :

- Chaque balise doit avoir une balise de fin (une balise ouvrante et une balise fermante) ;
- Les éléments ne doivent pas se chevaucher et doivent bien s'imbriquer ;
- Un élément ne peut avoir qu'un seul même attribut ;
- Un seul élément racine (on doit avoir un seul élément qui englobe tous les autres).

Déclaration XML

```
<?xml version="1.0" encoding="UTF-8"?>
```

- La déclaration XML s'écrit en début de document
- Elle indique la version utilisée de XML (toujours la version 1.0) et l'encodage du texte.

Commenter le texte

```
<!-- on écrit son commentaire -->
```

Les entités

```
&entité;
```

Permet d'utiliser des caractères interdits en XML comme le &.

`https://pad.libreon.fr/eoi6u4UjRh0-XGzRv\_bPzg?both`

Contraindre le XML

Pourquoi contraindre le XML ?

- Uniformiser l'encodage ;
- Collaborer à plusieurs sur un même projet ;
- Automatisation.

Spécifications du XML : *Document Type Definition* (DTD)

La **DTD** est une **liste de déclarations** qui permet de définir :

- la structure d'un document ;
- les éléments et attributs autorisés.

→ Un document XML peut être bien formé mais invalide car ne respecte pas les règles de la DTD !

Spécifications du XML : *Document Type Definition* (DTD)

Exemple (source W3C) :

```
<!DOCTYPE NEWSPAPER [  
  
  <!ELEMENT NEWSPAPER (ARTICLE+)>  
  <!ELEMENT ARTICLE (HEADLINE,BYLINE,LEAD,BODY,NOTES)>  
  <!ELEMENT HEADLINE (#PCDATA)>  
  <!ELEMENT BYLINE (#PCDATA)>  
  <!ELEMENT LEAD (#PCDATA)>  
  <!ELEMENT BODY (#PCDATA)>  
  <!ELEMENT NOTES (#PCDATA)>  
  
  <!ATTLIST ARTICLE AUTHOR CDATA #REQUIRED>  
  <!ATTLIST ARTICLE EDITOR CDATA #IMPLIED>  
  <!ATTLIST ARTICLE DATE CDATA #IMPLIED>  
  <!ATTLIST ARTICLE EDITION CDATA #IMPLIED>
```

Spécifications du XML : *Document Type Definition* (DTD)

Limites du DTD :

- N'est pas rédigé en XML ;
- Assez limité en terme d'attributs ;
- Difficile à lire ;
- Limité en espace de noms.

Définition :

« Un schéma spécifie **un ensemble de noms d'éléments**, **les noms et le type de données de tous les attributs** qui leur sont associés, et **les règles relatives aux contextes** dans lesquels ils peuvent apparaître. »

Burnard, Lou. « La TEI et le XML ». *Qu'est-ce que la Text Encoding Initiative ?*, OpenEdition Press, 2015, <https://doi.org/10.4000/books.oep.1298>.

Encoded Archival Description = crée dans les années 1990, c'est une DTD utilisée pour la description de fonds d'archive. Depuis 2007, est un format XML.

Exemple : Dossiers individuels de prisonniers de la Bastille

XML-TEI

« La TEI a été d'abord développée, il y a plus de trente ans, comme un projet de recherche dans le champ alors émergent du « Humanities computing ». L'idée originelle était de proposer un ensemble de recommandations sur la façon dont les chercheurs devraient créer des ressources textuelles « lisibles par ordinateur », qui soient adaptées aux besoins de la recherche - dans la mesure où un consensus existait sur le sujet -, mais qui soient également extensibles, puisque ces besoins changent et évoluent. »

Burnard, Lou. « Introduction ». *Qu'est-ce que la Text Encoding Initiative ?*, OpenEdition Press, 2015, <https://doi.org/10.4000/books.oep.129>

Text Encoding Initiative : créée en 1987 lors d'une conférence à Poughkeepsie sur les sciences humaines.

Projet est de créer des recommandations sur l'encodage de textes informatiques.

Trois principes selon Lou Burnard :

- le XML TEI s'intéresse au sens du texte plutôt qu'à son apparence ;
- le XML TEI est indépendant de tout environnement logiciel particulier ;
- le XML TEI a été conçu par la communauté scientifique, qui est aussi en charge de son développement continu.

TEI Consortium crée en 2000. Liste de recommandation :
<https://tei-c.org/guidelines/>

```
<div>
  <p>
    <persName> Toto </persName>
  </p>
</div>
```

Pour utiliser les balises TEI, il faut déclarer l'espace de noms :

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
```

Squelette d'un document TEI

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">  
  <teiHeader>  
  </teiHeader>  
  <text>  
    <body>  
      <p></p>  
    </body>  
  </text>  
</TEI>
```

Installations

Installer VS Code :

https://code.visualstudio.com/download?_exp_download=fb315fc982

Extension : Scholarly XML

Exercice : encoder en TEI

Encoder à nouveau l'extrait du *Bourgeois Gentilhomme* mais en XML-TEI en utilisant la documentation sur les textes théâtraux

```
<castList>  
<castItem>  
<speaker>  
<sp>
```

Exercice : encoder en TEI

Encoder le poème *Heureux qui, comme Ulysse...* de Joachim Du Bellay en s'appuyant sur la documentation sur les poèmes.