M1SOL041 : Représentation et traitement des documents électroniques
Cours 3 : Structurer un document XML-TEI

Marine Tiger
marine.tiger@sorbonne-universite.fr

Littératures françaises et comparée ED19, CELLF, Sorbonne Université

Introduction

Correction encodage *Bourgeois Gentilhomme*

Exemples de projets d'édition en TEI

- *Queen's Men Editions*
- *The Shelley-Godwin Archive*

Composants d'un document TEI

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
    <teiHeader>
    <!-- metadonnees -->
    </teiHeader>
    <text>
    <!-- corps du texte -->
    </text>
</TEI>
```

Le <teiHeader>

Structure de l'en-tête TEI

teiHeader : en-tête contenant les métadonnées décrivant le document.

4 composants principaux :

- `<fileDesc>` : description d'un document (obligatoire !) ;
- `<encodingDesc>` : description de l'encodage. Relation entre le document électronique et la ou les source(s) dont il est issu ;
- `<profileDesc>` : description non-bibliographique (langue du texte, contexte de production etc...) ;
- `<revisionDesc>` : historique des modifications du fichier.

Description d'un fichier avec `<fileDesc>`

Trois parties obligatoires :

- `<titleStmt>` : le titre de l'oeuvre ;
- `<publicationStmt>` : information sur la publication de l'oeuvre (date, lieu...) ;
- `<sourceDesc>` : information sur la source dont est tirée l'oeuvre (description du manuscrit par exemple).

Description d'un fichier avec <fileDesc>

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
    <teiHeader>
        <fileDesc>
            <titleStmt> Titre </titleStmt>
            <publicationStmt> Date et lieu de la
                publication</publicationStmt>
            <sourceDesc> Description de la source </sourceDesc>
        </fileDesc>
    </teiHeader>
    <text>
    </text>
</TEI>
```

Description des choix d'encodage avec `<encodingDesc>`

- `<projectDesc>` : description du projet ;
- `<editorialDecl>` : précisions sur les pratiques éditoriales employées ;
- `<variantEncoding>` : utilisé pour l'encodage d'apparat critique.

Description non-bibliographique avec <profileDesc>

- <creation> : origine du texte ;
- <langUsage> : langue d'écriture du texte ;
- <textDesc> : description de texte ;
- <particDesc> : description des participants réels ou fictifs ;
- <settingDesc> : description du contexte.

Exercice : en-tête TEI du *Bourgeois Gentilhomme*

Ecrire le `<teiHeader>` avec les éléments suivants et en s'appuyant sur les guidelines :

- `<fileDesc>` (et ses trois parties obligatoires)
- `<encodingDesc>`
- `<profileDesc>`
- `<revisionDesc>`

Le <text>

Structure de `<text>`

Dans l'élément `<text>`, on a :

- `<front>` : pour les préfaces ;
- `<body>` : pour le corps du texte (obligatoire !) ;
- `<back>` : pour les appendices, annexes etc...

Exemple

```
<text>
    <body>
        <div type="chapter" n="1">
            <head> Titre du chapitre </head>
            <div type="subparts" n="1">
                <p> du texte </p>
            </div>
        </div>
    </body>
</text>
```

Exercices

https://pad.libreon.fr/1plJ_-A-T_OY1E1TsSiRdQ

Personnaliser la TEI : ODD

Rappel : notion de schéma

Fondamentale en XML :

- Mettre en place un vocabulaire contrôlé ;
- Contraindre la structure d'un document (et l'adapter à nos besoins).

Vérifiable avec un validateur XML. Ex : `https://www.xmlvalidation.com/`.

Pour les contraintes en TEI, par exemple :

- « utilisez `<placeName>` pour les noms de lieux, `<persName>` pour les noms de personnes et `<name>` pour tout autre nom »

→ Ne peut pas être vérifié manuellement (on regarde les guidelines).

Pourquoi contraindre la TEI ?

Très pratique dans les projets d'édition numérique permet par exemple de :

- Contraindre les valeurs de l'attribut `@type` ;
- Documenter les choix d'édition.

Les schémas XML

- DTD ;
- XML Schema : crée par le W3C, écrit en XML, permet de définir la structure et le type de contenu d'un document XML ;
- Relax NG : écrit en XML, supporte les espaces de noms XML, peut créer des contraintes précises.

Les schémas XML : DTD

```
<!ELEMENT texte (chapitre+)>
<!ELEMENT chapitre (titre?, paragraphe+)>
<!ELEMENT titre (#PCDATA)>
<!ATTTLIST chapitre CDATA #REQUIRED>
```

Les schémas XML : XML Schema

```
<xs:element name="texte" maxOccurs="unbounded">
    <xs:complexType>
        <xs:sequence>
        <xs:element name="titre"
        type="xs:string"/>
        <xs:element name="chap" type="xs:decimal"
        minOccurs="0"/>
        </xs:sequence>
    </xs:complexType>
</xs:element>
```

Les schémas XML : Relax NG

```
<element name="edition">
    <zeroOrMore>
        <element name="texte">
            <element name="titre">
                <text/>
            </element>
            <element name="paragraphe">
                <text/>
            </element>
        </element>
    </zeroOrMore>
</element>
```

Combinaison de la DTD et du RNG : l'ODD

One Document Does It All

Comporte à la fois **un schéma de validation** et **une documentation** de ce schéma.
$\rightarrow$ un seul document XML avec les informations pour le traitement informatique et pour l'humain.

Deux types de personnalisation basiques

- ***tei_all*** = autorise tous les éléments définis par la TEI.
- ***tei_lite*** = propose environ une cinquantaine d'élément TEI (au lieu de 450).

Structure ODD : déclarations

```
<?xml version="1.0" encoding="UTF-8"?>
<?xml-model href="url vers odd rng"
type="application/xml"
    schematypens="http://relaxng.org/ns/structure/1.0"?>
<?xml-model
href="url vers odd rng"
schematypens="http://purl.oclc.org/dsdl/schematron"?>
```

Structure ODD : en-tête

```
<TEI xmlns="http://www.tei-c.org/ns/1.0"
     xmlns:xi="http://www.w3.org/2001/XInclude"
  xmlns:sch="http://purl.oclc.org/dsdl/schematron">
  <teiHeader>
    <fileDesc>
      <titleStmt></titleStmt>
      <publicationStmt></publicationStmt>
      <sourceDesc></sourceDesc>
    </fileDesc>
    <revisionDesc></revisionDesc>
  </teiHeader>
  <text>
    <body></body>
  </text>
</TEI>
```

Structure ODD : corps du texte

- `<schemaSpec>` : défini les spécifications du schéma ;
- `<moduleRef>` : défini un module qui doit être présent dans l'encodage ;
- `<elementSpec>` : permet de modifier, ajouter, contraindre un élément ;
- `<attList>` : permet de contraindre le contenu d'un attribut.

Structure ODD : corps du texte

```
<schemaSpec ident="RCF_comité" start="TEI">

  <!-- Règles d'encodage pour le header -->
  <moduleRef key="header"
    include="calendar calendarDesc change edition editionStmt encodingDesc fileDesc
    idno listChange listPrefixDef namespace prefixDef profileDesc publicationStmt
    rendition revisionDesc schemaRef sourceDesc teiHeader titleStmt"/>
  <!-- Le module "msdescription" permet de décrire les registres. -->
  <moduleRef key="msdescription" include="institution msDesc msIdentifier repository source"/>

</schemaSpec>
```

Structure ODD : corps du texte

```
<!-- Pour la <div1> -->
<elementSpec ident="div1" mode="change" module="textstructure">
    <attList>
      <!-- Contrainte pour obliger l'attribut @type pour indiquer le type d'assemblée lister dans
          <valItem>-->
      <attDef ident="type" mode="replace" usage="req">
        <constraintSpec ident="type" scheme="schematron">
          <constraint>
            <sch:rule context="tei:div1">
              <sch:assert test="@type" role="error">Ajouter le type d'assemblée dans un
                attribut @type.</sch:assert>
            </sch:rule>
          </constraint>
        </constraintSpec>
        <valList type="closed">

          <!-- Liste (non-exhaustive) des types d'assemblée pour le 17ème-18ème siècle  -->
          <valItem ident="ass_ord">
            <desc>Assemblée ordinaire. Ce sont les séances quotidiennes de l'assemblée de la
              fin du 17ème à la fin du 18ème siècle.</desc>
          </valItem>
          <valItem ident="ass_extraord">
            <desc>Assemblée extraordinaire. Les comédien.nes sont réunies pour parler de
              sujet important. Terminologie employée entre fin 17ème-fin 18ème
              siècle.</desc>
          </valItem>
          <valItem ident="distribution_roles">
            <desc>Certaines assemblées sont dédiées principalement à la distribution des
              rôles d'une pièce.</desc>
          </valItem>
          <valItem ident="amendes">
  </attDef>
</attList>
</elementSpec>
```

Créer son ODD

- Outil Roma : `https://roma.tei-c.org/members`

Exercice : générer une ODD pour le *Bourgeois Gentilhomme*

Générer une ODD en utilisant l'outil Roma.